

합성곱 신경망을 이용한 언어장애인용 문장 인식

김종우[○] 윤기현 허진혁 전광일

한국산업기술대학교 컴퓨터공학부

karr0821@gmail.com, ykh094@naver.com, jinhur1@naver.com, gijeon@kpu.ac.kr

Sentence Recognition using Convolutional Neural Network for Speech Disabled

Jongwoo Kim[○], Kihyeon Yun, Jinhyuck Hur, Gwangil Jeon

Dept. of Computer Engineering, Korea Polytechnic University

요 약

음성인식 기술의 발전으로 사람들의 생활 편의성이 증대되었지만 언어장애인의 경우 일반인을 대상으로 개발된 음성인식의 이용이 불가능하다. 본 논문에서는 합성곱 신경망(CNN, Convolutional Neural Network)을 이용하여 언어장애인의 음성을 시스피커 명령어 문장으로 변환하는 방법을 제시한다. 음성 파일을 스펙트로그램(Spectrogram) 이미지 파일로 변환하여 합성곱 신경망의 학습데이터로 사용한다. 합성곱 신경망은 언어장애인의 음성에 대한 분류를 수행한다. 본 논문을 통해 발음이 부정확한 언어장애인도 시스피커와 같은 음성인식 기술을 이용할 수 있음을 기대한다.

1. 서 론

4차 산업혁명 시대에 들어서며 빅데이터, 인공지능, 사물인터넷 기술의 많은 발전이 이루어졌다. 특히 시스피커와 같은 음성인식 기술이 널리 보급됨에 따라 많은 사람들의 일상 생활 속 편의성이 증대되었다. 하지만 언어장애인과 같이 음성인식 기술의 혜택으로부터 소외되는 계층이 존재하며 그 이유는 크게 다음과 같다.

- 1) 현재 널리 보급된 음성인식은 일반인들의 표준 발음에 최적화되어 있다. 따라서 언어장애인의 부정확한 발음을 인식하기 어렵다.
- 2) 한 언어에는 표준화된 발음 기준이 존재하기 때문에 대량의 데이터를 활용하여 음성인식을 개발할 수 있다. 반면, 언어장애인의 발음은 개인차 정도가 심하여 대량의 데이터 수집 및 활용이 힘들다.

따라서 일반적으로 음성인식을 이용할 수 없는 언어장애인이 한정적으로나마 그 혜택을 누릴 수 있는 방법을 제시하고자 한다. 언어장애인마다 발음의 차이가 커서 대량의 데이터를 활용할 수 없기 때문에 비교적 적은 데이터만으로도 일정 수준의 성능을 낼 수 있는 합성곱 신경망을 이용한다. 시스피커 명령어에 대한 언어장애인의 음성을 입력으로 받아 스펙트로그램으로 변환하여 데이터로 사용한다. 합성곱 신경망은 이에 대한 분류를 수행하여 알맞은 문장을 인식하게 되며, 이를 출력함으로써 시스피커를 작동시킨다.

현재 텍스트를 입력으로 받거나 버튼을 이용하는 방식의 애플리케이션은 다수 존재하지만 언어장애는 지체장애, 뇌성마비 등 다른 장애와 복합적으로 발생하여 거

동이 불편한 경우도 많이 있기 때문에 사용이 힘들 수 있다. 따라서 시스피커를 통해 가정 내 전자기기를 제어할 수 있다는 점은 일반인에 비해 그 효용성이 더 클 것으로 예상된다.

2. 관련 연구

2.1 합성곱 신경망(Convolutional Neural Network)

합성곱 신경망[1]은 합성곱 계층(Convolutional Layer)과 풀링 계층(Pooling Layer)이 반복적으로 존재하고 마지막에는 완전 연결 계층(Fully-Connected Layer)으로 구성된다.

합성곱 계층은 입력 이미지와 가중치인 필터(Filter)의 합성곱 연산을 수행하여 특징 맵(Feature map)을 출력한다. 풀링 계층은 입력된 이미지의 크기를 압축함으로써 특징의 위치 변동에 따른 민감도를 줄이는 기능을 수행한다.[2]

2.2 음성 분류

음성 데이터에는 목소리의 높낮이, 속도, 어휘 등 많은 정보가 담겨있다. 인공지능 기술로 이를 분석함으로써 TTS, 음성 검색, 감정 분석 등 다양한 분야에 활용된다. 도시 내 각종 소리에 대한 소음 분류나 화자의 성별이나 연령대 등을 구분하는 화자 분류에 관한 연구 또한 활발히 진행되고 있다. 합성곱 신경망은 이러한 분류 문제에 많이 사용되고 있으며 음성 데이터를 멜-스펙트로그램(Mel-spectrogram)으로 벡터화하여 학습데이터로 활용한 사례가 존재한다.[3]

2.3 음성인식 시스템




그림 1 음성인식 시스템 구성도

가상비서의 음성인식 시스템은 <그림1>[4]의 구성을 가진다. 음성 데이터를 컴퓨터가 이해하는 텍스트로 변환하는 ASR(Automatic Speech Recognition)[5], 문장의 의미를 파악하는 NLU(Natural Language Understanding), 텍스트를 음성 데이터로 변환하는 TTS(Text to Speech)가 사용된다. ASR에서 동작하는 인공지능망은 일반인 발음에 최적화되어 있으며 언어장애인과 같이 부정확한 발음은 인식하지 못한다. 따라서 본 연구에서는 ①에서 ②로 넘어가는 과정에서 언어장애인의 음성을 올바른 문장으로 변환하여 음성인식 시스템으로 넘겨주는 것을 목표로 한다.

3. 데이터 수집 및 처리



그림 2 스펙트로그램 원본(좌)과 소음제거(우)

언어장애인의 발음은 개인의 정도차가 심하기 때문에 표준적인 인공지능망 모델을 미리 구현하여 사용하기 힘들다. 따라서 사용자 개인의 음성 데이터를 사용하여 개인화된 모델 구축이 필요하다. 학부생 신분으로는 언어장애인의 데이터를 수집하고 활용하는 것에 많은 제약이 따르기 때문에 일반인이 입에 이물질을 물고 발음하는 음성 데이터를 수집하여 인공지능망 학습에 사용하였다. 일반 음성인식 시스템으로는 이러한 발음을 인식하지 못하기 때문에 충분히 언어장애인 개인의 데이터를 대체할 수 있다고 생각한다. 최종적으로 약 60분의 음성 데이터를 수집하여 인공지능망을 학습하였다. 음성 데이터는 시스피커 명령어 한 문장을 말하기에 충분한 시간인 3초의 길이로 일반화하고 인공지능망의 지도학습을 위해 각 데이터에 대해서 <표1>과 같이 labeling을 수행한다.

표 1 Label List

명령어	인덱스	명령어	인덱스
거실 불 켜	0	화장실 불 꺼줘	5
거실 불 꺼	1	TV 채널 올려줘	6
안방 불 켜줘	2	TV 채널 내려줘	7
안방 불 꺼줘	3	현관문 열어줘	8
화장실 불 켜줘	4	오늘 날씨 어때	9

명령어 10개의 클래스 분류에 사용된 데이터는 총 800개이며 학습데이터 700개, 테스트 데이터 100개로 나누어서 활용하였다. 연구는 초기 500개의 데이터로 신경망을 학습한 뒤 실제 사용하면서 피드백을 주어 추가 데이터를 축적, 신경망을 재학습시키는 형태로 진행하였다.

합성곱 신경망은 시각 이미지 파일을 입력 데이터로 사용하기 때문에 SoX[6] API를 사용하여 음성 파일을 100X100 크기의 스펙트로그램 이미지 파일로 변환한다. 스펙트로그램은 3개의 채널(RGB)로 구성되며 각 채널은 0~255의 값을 갖는다. 각 채널의 값을 분석한 결과, 사람이 직접 녹음한 음성처럼 큰 소리는 배경 소음에 비해 GREEN 값이 현저하게 높음을 확인하였다. 인공지능망이 이미지의 특징을 보다 수월하게 인식할 수 있도록 OpenCV[7] API를 이용하여 32이하의 GREEN 값을 가진 소리에 대해 <그림2>와 같이 소음제거를 수행한다. GREEN 채널 값의 기준치를 너무 높게 잡으면 원본 데이터의 손실이 커지며 조용한 실내 환경에서는 해당 기준치가 적절하다고 판단하였다.

4. 합성곱 신경망 모델




그림 3 합성곱 신경망 구조

<그림3>은 연구에 사용한 합성곱 신경망의 구조로 Python과 Tensorflow를 사용하여 신경망을 구축하였다. 3개의 합성곱 계층(Conv.1, 2, 3)과 1개의 풀링 계층(Pooling)이 존재하며 마지막에는 완전 연결 계층(Fully Connected)으로 구성된다. 합성곱 계층과 완전 연결 계층에서는 활성화 함수(Activation function)로 ReLU 함수를 사용한다. 풀링 계층에서는 2X2 크기의 Max pooling 기법을 사용하여 입력 이미지 크기와 데이터 변화에 따른 민감도를 줄인다.

학습데이터를 미니배치 방식으로 구성하고 가중치의 갱신 강도를 적응적으로 조정하는 Adam Optimizer[8] 알고리즘을 사용하여 신경망 학습을 진행하였다. 이때 과적합(Overfitting)을 방지하기 위해 25%의 Dropout을 적용한다.

모든 합성곱 계층과 풀링 계층의 작업을 수행하게 되면 초기의 100X100 크기의 입력 이미지는 13X13 크기를 갖는 16개의 특징 맵으로 출력된다. 세번째 합성곱 계층(Conv.3)의 출력은 3차원 형태(가로, 세로, 채널)이므로 완전 연결 계층에 알맞은 1차원 형태로 변경한다. 출력 계층에서는 Softmax 함수를 적용하여 <표1>의 명령어 목록 내에서 가장 높은 점수(예측값)에 해당하는 문장을 출력한다.




그림 4 CNN과 Template matching의 인식률

<그림4>는 학습한 신경망과 템플릿 매칭(Template Matching) 방식을 사용하여 직접 인식률을 비교한 그래프이다. 템플릿 매칭이란, 대상에 대한 템플릿을 사전에 마련해두고 유사도를 비교하는 패턴인식 방법이다.[9] 충분한 학습데이터(약 500개)가 확보된 시점 이후에는 단순한 템플릿 비교 방식보다 신경망을 사용하는 것이 더 높은 인식률을 보인다. 최종적으로 700개의 데이터를 학습한 신경망은 약 89%의 인식률이 나온다.

5. 결론 및 향후 연구

본 논문에서는 발음이 부정확한 언어장애인도 음성인식 기술을 사용할 수 있도록 합성곱 신경망과 스펙트로그램을 이용하여 음성을 통해 문장을 인식할 수 있는

방법을 연구하였다.

스펙트로그램의 데이터 전처리에 있어 단순히 데이터 크기를 맞추고 RGB 채널 값을 비교하여 소음을 제거하는 작업만 수행하였다. 소음이 있는 환경에서 녹음한 데이터에 대해서는 학습 성능이 향상되어 약 10%의 인식을 상승을 보인 반면, 소음이 적은 데이터와는 큰 차이가 없었다. 추가적으로 스펙트로그램의 주파수 범위, 프레임 수 등을 보다 전문적으로 연구하고 신경망의 특징 추출에 있어 최적화된 값을 적용함으로써 인식률을 향상시킬 수 있을 것으로 예상된다.

연구에 사용된 신경망 구조는 700개의 데이터를 학습하였을 때 90%에 가까운 인식률을 보인다. 이후 900개 가량의 데이터를 학습하여도 인식률의 차이가 없는 것으로 보아 신경망 구조의 한계로 판단된다. 또한, 연구는 10개로 제한된 문장 분류를 진행한 것으로 실제 사용될 문장의 수가 증가함에 따라 보다 깊은 신경망 구조로 개선할 필요가 있다.

참 고 문 헌

- [1] Yann LeCun, Leon Bottou, Yoshua Bengio and Patrick Haffner, "Gradient-Based Learning Applied to Document Recognition", PROC OF THE IEEE NOVEMBER, 1998.
- [2] 안성만, "딥러닝의 모형과 응용사례", J Intell Inform Syst, pp. 131-133, 2016.
- [3] 박대서, 방준일, 김화중, 고영준, "CNN을 이용한 음성 데이터 성별 및 연령 분류 기술 연구", 한국정보기술학회 논문지, vol.16, no.11, pp. 11-21, 2018.
- [4] 김정돈, "음성인식 가상비서 기술 동향 및 전망", KEIT PD ISSUE REPORT APRIL, vol.19-4, pp. 3-15, 2019.
- [5] Martin Cooke, Phil Green, Ljubomir Josifovski and Ascension Vizinho, "Robust automatic speech recognition with missing and unreliable acoustic data", Speech Communication, vol.34, pp. 267-285, 2001.
- [6] Chris Bagwell, "SoX - Sound eXchange", the Swiss Army knife of audio manipulation, 2014.
- [7] Gary Bradski and Adrian Kaehler, "Learning OpenCV: Computer Vision with the OpenCV Library", O'Reilly Media, 2008.
- [8] Diederik P. Kingma and Jimmy Lei Ba, "Adam: a Method for Stochastic Optimization", ICLR, 2015.
- [9] Roberto Brunelli, "Template Matching Techniques in Computer Vision: Theory and Practice", Wiley, 2009.